

Sistema de Detecção de Faixas de Trânsito para Assistência na Direção de Veículos

*Utilizando Algoritmos de Visão Computacional para Navegação Segura e Eficiente

1st Fernanda de Castro Fernandes

Escola de Engenharia Elétrica, Mecânica e de Computação
Universidade Federal de Goiás
Goiânia, Goiás
castro.fernanda@discente.ufg.br

2nd Kauan Divino Pouso Mariano

Instituto de Informática
Universidade Federal de Goiás
Goiânia, Goiás
kauan@discente.ufg.br

3rd Luan Gabriel Silva Oliveira

Instituto de Informática
Universidade Federal de Goiás
Goiânia, Goiás
luangabriel@discente.ufg.br

4th Lyan Eduardo Sakuno Rodrigues

Instituto de Informática
Universidade Federal de Goiás
Goiânia, Goiás
lyan@discente.ufg.br

5th Matheus Andrade Brandao

Instituto de Informática
Universidade Federal de Goiás
Goiânia, Goiás
matheus_brandao@discente.ufg.br

Abstract—O projeto propõe a criação de um sistema avançado de detecção de faixas de trânsito, visando auxílio na condução de veículos autônomos e convencionais. Utilizando abordagens modernas de visão computacional, o sistema busca superar desafios como condições climáticas adversas e faixas desgastadas. A iniciativa representa um passo significativo na direção de transportes mais seguros e eficientes, contribuindo para o avanço da tecnologia de condução autônoma.

Index Terms—Detecção de Faixas de Trânsito, Visão Computacional, Condução Autônoma, Segurança Viária

I. INTRODUÇÃO E REVISÃO BIBLIOGRÁFICA

O trânsito contemporâneo exige soluções inovadoras para aprimorar a segurança e eficiência nas estradas e vias urbanas. A detecção e rastreamento de faixas em vias é fundamental para sistemas avançados de assistência ao motorista e, em um contexto mais amplo, para veículos autônomos. A habilidade de identificar com precisão os limites das faixas é essencial para assegurar a segurança do veículo e de seus ocupantes, assim como para otimizar a fluidez do tráfego. Contudo, a detecção de faixas em ambientes dinâmicos e sob variadas condições de iluminação e clima representa um desafio considerável.

O presente projeto visa abordar este desafio por meio de técnicas de visão computacional tradicional. A escolha por esta abordagem decorre da necessidade de criar algoritmos robustos e eficientes, capazes de operar em tempo real e em diversos cenários de condução. O projeto foi inspirado pelo artigo "Ultra Fast Structure-aware Deep Lane Detection". Este trabalho propôs uma metodologia inovadora que integra técnicas de aprendizado profundo com uma compreensão estrutural das faixas, possibilitando detecções ágeis e acuradas. Embora o projeto em questão tenha decidido não empregar técnicas de aprendizado de máquina, os insights estruturais e

as estratégias de pré-processamento do referido artigo serviram como fundamentação para o desenvolvimento do algoritmo.

A detecção acurada de faixas é vital para diversas aplicações, desde a assistência básica ao motorista até a navegação autônoma de veículos. A abordagem tradicional de visão computacional, apesar de não ser tão flexível quanto as técnicas de aprendizado profundo, apresenta a vantagem de demandar menos recursos computacionais. Isso a torna apropriada para implementações em tempo real e em dispositivos com capacidades computacionais restritas..

II. FUNDAMENTOS TEÓRICOS

A visão computacional, em sua essência, aspira a replicar a habilidade humana de interpretar e tomar decisões com base em informações visuais. No âmbito da detecção de faixas em vias, essa capacidade é manifestada pela identificação de padrões específicos nas imagens que denotam os limites das faixas. Diversas técnicas e algoritmos foram implementados neste projeto para atingir tal finalidade.

A. Calibração da Câmera e Correção de Distorção

A distorção é uma anomalia frequentemente observada em imagens obtidas por câmeras, resultante da imperfeição na projeção de pontos de um objeto tridimensional para pontos em uma imagem bidimensional. Para mitigar essa distorção, empregamos funções disponibilizadas pelo OpenCV, tais como 'cv2.findChessboardCorners', 'cv2.calibrateCamera' e 'cv2.undistort'. A calibração é conduzida utilizando imagens de um tabuleiro de xadrez, padrão este amplamente reconhecido e adotado em processos de calibração de câmeras.

B. Transformação de Perspectiva

Subsequentemente à correção da distorção, a imagem é submetida a uma transformação para adquirir uma per-

spectiva aérea, ou "visão de pássaro". Tal transformação é imperativa para alinhar as faixas de modo que se apresentem paralelamente, simplificando assim sua detecção. A transformação é efetuada mediante pontos de origem e destino estabelecidos empiricamente, utilizando a função 'cv2.getPerspectiveTransform'..

C. Geração de Imagem Binária Thresholded

Uma etapa crucial é a distinção das faixas em relação ao restante da imagem. Diversas técnicas foram avaliadas, incluindo o thresholding de gradientes e o thresholding de canais de cores específicos. A fusão de canais de cores de distintos espaços cromáticos, como RGB, HLS, HSV e LAB, demonstrou eficácia na identificação de faixas brancas e amarelas sob variadas condições luminosas.

D. Detecção de Linha de Faixa

Com a imagem binária em mãos, o passo subsequente consiste em discernir os pixels associados às faixas. Tal tarefa é realizada por meio de técnicas como o método de janelas deslizantes e a abordagem de busca adaptativa. O objetivo é rastrear os pixels associados à faixa e ajustá-los a um polinômio de segundo grau, que delinea a trajetória da faixa.

E. Conversão para Espaço do Mundo Real

A fim de extrair métricas relevantes, como a curvatura da faixa, é imperativo transpor as medidas do domínio pixelar para o espaço real. Tal transição é efetuada por meio de conversões empíricas, fundamentadas nas normativas viárias dos EUA, local de origem dos vídeos exemplificativos utilizados neste projeto.

A integração dessas técnicas e algoritmos viabiliza a detecção precisa e robusta das faixas em uma ampla gama de cenários de condução. Esta abordagem foi parcialmente inspirada pelo artigo "Ultra Fast Structure-aware Deep Lane Detection" e adaptada para uma perspectiva tradicional de visão computacional

III. METODOLOGIA

A metodologia empregada neste projeto consiste em uma combinação de técnicas de visão computacional tradicional, organizadas em um pipeline sequencial para o processamento de imagens e vídeos. O propósito central é a identificação e rastreamento eficaz e preciso dos limites das faixas de rodagem.

Inicialmente, antes de processar qualquer imagem ou vídeo, é imperativo garantir a ausência de distorções nas imagens capturadas pela câmera. Utilizando um conjunto de imagens de um tabuleiro de xadrez como referência, a câmera é calibrada. A matriz resultante da calibração, juntamente com os coeficientes de distorção, são armazenados para aplicações subsequentes. Assim, qualquer imagem ou quadro de vídeo que seja processado posteriormente é corrigido com base nesses parâmetros.

Após a correção, a imagem é submetida a uma transformação de perspectiva para obter uma "visão de

pássaro". Este processo envolve a seleção de quatro pontos na imagem original e sua correspondente projeção em uma vista superior. O resultado é uma representação onde as faixas são visualizadas de cima, tornando-as aproximadamente paralelas e, conseqüentemente, facilitando sua detecção. Tendo isso em mente, é possível prever uma perda de acurácia ao realizar essa transformação em trechos com curvas.

Posteriormente, a imagem transformada é convertida em uma representação binária, na qual os pixels correspondentes às faixas são destacados. Este efeito é alcançado por meio de uma combinação de thresholding baseado em gradientes e canais de cores. Um insight interessante advindo da análise do dataset foi a necessidade de um threshold adaptável dadas as condições precárias das rodovias, especialmente caso fosse usado em estradas brasileiras. Espaços cromáticos variados, como RGB, HLS, HSV e LAB, são explorados para maximizar a eficácia da detecção de faixas em diferentes condições de iluminação. O modelo usa máscaras de detecção de pixels amarelos e brancos com maior frequência, o que exige maior robustez na detecção de tais features (as faixas rodoviárias brasileiras, do dataset CULane e do dataset TuSimple são brancas ou amarelas). Abaixo, tem-se um recorte do código usado nas citadas máscaras.

```
### HLS color space
hls = cv2.cvtColor(img, cv2.COLOR_RGB2HLS)
L = hls[:, :, 1]
L_max, L_mean = np.max(L), np.mean(L)
S = hls[:, :, 2]
S_max, S_mean = np.max(S), np.mean(S)

# YELLOW
L_adapt_yellow = max(80, int(L_mean * 1.25))
S_adapt_yellow = max(int(S_max * 0.25), int(S_mean * 0.25))
hls_low_yellow = np.array((15, L_adapt_yellow, S_adapt_yellow))
hls_high_yellow = np.array((30, 255, 255))

hls_yellow = binary_threshold(hls, hls_low_yellow, hls_high_yellow)

# WHITE
L_adapt_white =
max(160, int(L_max * 0.8), int(L_mean * 1.25))
hls_low_white = np.array((0, L_adapt_white, S_adapt_white, 0))
hls_high_white = np.array((255, 255, 255))

hls_white = binary_threshold(hls, hls_low_white, hls_high_white)

hls_binary = hls_yellow | hls_white
```

Com a imagem binária preparada, o passo subsequente envolve a identificação dos pixels associados às faixas e seu rastreamento ao longo da imagem. Inicialmente, é empregado um método de janelas deslizantes, que identifica regiões com alta densidade de pixels correspondentes às faixas. Após a identificação das faixas em uma sequência de frames, uma técnica de busca adaptativa é introduzida para rastrear os pixels

da faixa em frames subsequentes, otimizando a eficiência e precisão do processo. Essa busca adaptativa depende dos coeficientes polinomiais usados na detecção do caminho da pista do frame anterior.

Os pixels identificados são, então, transpostos para o espaço real, possibilitando o cálculo de métricas cruciais, como a curvatura da faixa e a posição relativa do veículo em relação ao centro da via. Por fim, as faixas detectadas são projetadas de volta à imagem original, proporcionando uma visualização nítida de seus limites. Informações adicionais, como a curvatura da faixa e a posição do veículo, são superpostas à imagem, oferecendo um feedback em tempo real ao usuário.

A implementação deste pipeline foi realizada em um ambiente Jupyter Notebook, favorecendo uma exploração interativa e iterativa das diversas etapas e técnicas. Adicionalmente, a estruturação do projeto foi concebida de forma modular, com cada etapa do pipeline claramente delineada e isolada, o que facilita processos de otimização e depuração.

IV. RESULTADOS E CONCLUSÕES

A implementação do pipeline de detecção de faixas, fundamentada em técnicas de visão computacional tradicional, exibiu resultados alentadores em diversos cenários de condução.

Em relação aos resultados obtidos, o algoritmo demonstrou competência na identificação precisa das faixas sob variadas condições de iluminação e textura da via. Especificamente, a técnica de transformação de perspectiva, aliada à combinação de thresholding baseado em gradientes e canais de cores, mostrou-se eficiente na segmentação das faixas em contraste com o restante da imagem. Ao avaliar sequências de vídeo, como as contidas em video-exemplo.mp4, o algoritmo exibiu robustez, mantendo a capacidade de rastrear as faixas consistentemente, mesmo sob condições de iluminação flutuante e superfícies de via heterogêneas. Adicionalmente, métricas como a curvatura da faixa e a posição relativa do veículo em relação ao centro da via foram calculadas com acurácia, ressaltando o potencial da abordagem para aplicações em sistemas de assistência ao condutor ou em contextos de veículos autônomos.

No entanto, a metodologia apresentou desafios e limitações. Em condições extremas, particularmente em áreas com sombras intensas ou reflexos luminosos, a precisão da detecção foi comprometida. Adicionalmente, o algoritmo demonstrou vulnerabilidades em vias com curvas bruscas, uma consequência das suposições adotadas durante a transformação de perspectiva.

Concluindo, a abordagem baseada em visão computacional tradicional, apesar de exigir um refinamento meticuloso e otimização, emergiu como uma ferramenta de relevância na detecção e rastreamento de faixas. A estrutura do projeto foi influenciada pelo artigo "Ultra Fast Structure-aware Deep Lane Detection", mesmo que as técnicas de aprendizado profundo não tenham sido diretamente incorporadas. Este estudo reforçou a essencialidade de uma calibração minuciosa da câmera, da transformação de perspectiva adequada e da fusão de distintas técnicas de thresholding para a obtenção de

uma imagem binária de alta qualidade. A natureza modular do projeto favoreceu uma otimização iterativa, permitindo a incorporação de aprimoramentos com base nas análises dos resultados. Embora a metodologia tradicional apresente suas restrições, especialmente quando posta em paralelo com técnicas de aprendizado profundo, ela proporciona compreensões profundas sobre a detecção de faixas e estabelece um alicerce para futuras inovações e refinamentos.

REFERENCES

- [1] Q. Zequn, W. Huanyu, L. Xi. "Ultra Fast Structure-aware Deep Lane Detection," , Computer Vision – ECCV 2020, vol 12369, pp 276–291, novembro 2020.
- [2] Q. Zequn, W. Huanyu, L. Xi. "Ultra Fast Deep Lane Detection With Hybrid Anchor Driven Ordinal Classification" , IEEE Transactions on Pattern Analysis and Machine Intelligence 2022, pp 1-14, junho 2020
- [3] Luo, Y., Zheng, C., Yan, X., Kun, T., Zheng, C., Cui, S., Li, Z. (2023). LATR: 3D Lane Detection from Monocular Images with Transformer. arXiv preprint arXiv:2308.04583
- [4] Hou, Y. (2019). Agnostic Lane Detection. arXiv preprint arXiv:1905.03704
- [5] Abualsaud, H., Liu, S., Lu, D., Situ, K., Rangesh, A., Trivedi, M. M. (2021). LaneAF: Robust Multi-Lane Detection with Affinity Fields. arXiv preprint arXiv:2103.12040

V. LINK DO VIDEO DA APRESENTAÇÃO

<https://drive.google.com/file/d/16XLuNhyP1qww8yNNuZiBSCzx2LVLOUrF/view?usp=sharing>